

Redes Neurais MLP

Construção de baseline e estudo de ablação em problemas de regressão e classificação

Leonardo Arazo

20 de setembro de 2026

Resumo

Este trabalho constrói, para dois problemas de naturezas distintas — regressão sobre uma função sintética e classificação de imagens no Fashion-MNIST —, um modelo MLP *baseline* treinado com SGD puro, e avalia o efeito de quatro componentes adicionados isoladamente: regularização L1, regularização L2, *dropout* e *momentum*. Todos os experimentos usam três sementes e reportam média e desvio. O resultado central é que os mesmos quatro componentes, sob o mesmo motor de treino e o mesmo protocolo, produziram conclusões opostas nos dois problemas: na regressão os três regularizadores degradaram o desempenho de forma monotônica, com ótimo em zero; na classificação todos apresentaram melhor valor positivo, com o *dropout* reduzindo a distância entre erro de treino e de validação de $18,2\times$ para $3,9\times$. Argumenta-se que a diferença é explicada pela quantidade de sobreajuste disponível para ser combatida em cada problema, e que o limite de desempenho na classificação não é de sobreajuste, mas de representação.

1 Introdução

O objetivo deste trabalho é duplo. Primeiro, construir empiricamente um modelo MLP de referência (*baseline*) para um problema de regressão e um de classificação, usando exclusivamente descida de gradiente estocástica sem otimizações. Segundo, medir o efeito de quatro componentes acrescentados individualmente a esse baseline, mantendo a arquitetura inalterada.

A escolha de tratar os dois problemas com o mesmo código e o mesmo protocolo é deliberada: diferenças observadas entre eles podem então ser atribuídas ao problema, e não ao método. Como se verá na Seção 5, essa decisão é o que torna o resultado principal interpretável.

Nota sobre terminologia. O enunciado denomina *estudo de ablação* o procedimento adotado. No uso corrente da literatura, ablação designa a *remoção* de componentes de um sistema completo para medir a contribuição de cada um; aqui parte-se de uma rede mínima e os componentes são *acrescentados*. Mantém-se a nomenclatura do enunciado, registrada a distinção.

2 Metodologia

2.1 Protocolo experimental

Todas as decisões — seleção de arquitetura, de hiperparâmetros e de valores dos componentes — foram tomadas no conjunto de validação. O conjunto de teste foi mantido lacrado e utilizado uma única vez por modelo, ao final.

Separação das fontes de aleatoriedade. Existem duas fontes independentes de variação: a geração do conjunto de dados e o processo de treino (inicialização de pesos e ordem dos *mini-batches*). Variá-las simultaneamente impediria atribuir qualquer diferença observada a uma causa específica. Adotou-se, portanto, semente fixa e única para os dados (`SEED_DADOS = 0`)

e três sementes distintas apenas para o treino ([1,2,3]). Todos os modelos de um mesmo problema observam exatamente os mesmos dados, e partem dos mesmos pesos iniciais, de modo que a diferença entre eles é o componente adicionado.

Reporte estatístico. Todos os resultados são apresentados como média $\pm$ desvio-padrão sobre as três sementes. Adota-se como critério de significância que a diferença entre dois modelos deve exceder aproximadamente dois erros-padrão da média para ser considerada sinal; diferenças menores são reportadas como não conclusivas.

Orçamento fixo de épocas. O enunciado determina que o baseline não utilize regularização. Como a parada antecipada (*early stopping*) é uma forma de regularização, empregá-la contaminaria o baseline com um mecanismo que deveria estar reservado às variantes. Adotou-se, portanto, orçamento fixo de épocas, idêntico para todos os modelos de um mesmo problema, reportando-se o estado ao final do orçamento. O valor do orçamento foi calibrado experimentalmente antes da busca, conforme descrito nas Seções 3.3 e 4.2.

2.2 Implementação

O motor de treino foi implementado uma única vez e reutilizado integralmente nos dois problemas. As funções de construção da rede, de treino e de fixação de sementes são idênticas; a transição de regressão para classificação exige apenas três alterações: a dimensionalidade de entrada e saída ($1 \rightarrow 1$ contra $784 \rightarrow 10$), a função de custo (erro quadrático médio contra entropia cruzada) e a função de métricas.

Duas decisões de implementação merecem registro. A camada de saída não possui função de ativação em nenhum dos dois casos: na regressão porque o alvo é um número real arbitrário; na classificação porque `nn.CrossEntropyLoss` aplica *log-softmax* internamente, e uma aplicação adicional degradaria o treino silenciosamente. Além disso, a regularização L2 é obtida pelo parâmetro `weight_decay` do otimizador — a derivada de $\frac{\lambda}{2n} \sum_w w^2$ é $\frac{\lambda}{n} w$, exatamente o termo somado ao gradiente —, ao passo que a L1 exige implementação manual, por $|w|$ não possuir derivada analítica embutida. Na L1 excluíram-se os termos de viés da penalização. Registra-se a assimetria resultante: o `weight_decay` do PyTorch penaliza também os vieses.

3 Problema 1: Regressão

3.1 Geração dos dados

O enunciado determina a geração de uma função não trivial de uma variável independente, contendo não linearidades, descontinuidades e ruído. Adotou-se

$$f(x) = \sin(3x) + 0,3x + 1,5 \cdot \mathbf{1}[x > 2] + \varepsilon, \quad x \sim \mathcal{U}(-5, 5), \quad \varepsilon \sim \mathcal{N}(0, 0,2^2), \quad (1)$$

com $n = 300$ pontos, divididos em 210 para treino, 45 para validação e 45 para teste. Cada termo cumpre uma função distinta: o termo linear é trivialmente aprendido e serve de verificação de sanidade; o termo senoidal, com aproximadamente 4,8 períodos no domínio, é o que discrimina arquiteturas; e a descontinuidade em $x = 2$ constitui um limite representacional, discutido na Seção 3.6.

A amostragem de x é uniforme e aleatória, e não em grade regular, de modo que as lacunas irregulares entre pontos permitam observar o comportamento interpolatório da rede. As variáveis foram padronizadas com média e desvio calculados *exclusivamente* sobre o conjunto de treino, e as métricas revertidas à escala original de $f(x)$.

Escolha de n . O número de amostras controla diretamente a possibilidade de sobreajuste e, portanto, a possibilidade de os regularizadores exibirem qualquer efeito. Verificou-se $n = 150$ por precaução, obtendo-se $R^2 = 0,9683$ contra 0,9704 de $n = 300$, valores estatisticamente equivalentes; manteve-se $n = 300$.

3.2 Teto de desempenho

Com $\text{Var}(y) = 3,056$ e $\text{Var}(\varepsilon) = 0,04$, o desempenho máximo alcançável por qualquer modelo é

$$R_{\max}^2 = 1 - \frac{0,04}{3,056} = 0,987, \quad \text{MSE}_{\text{irreduzível}} = 0,04. \quad (2)$$

Todos os resultados devem ser lidos contra esse teto. Um R^2 próximo de 1,0 não indicaria excelência, mas ajuste ao ruído.

3.3 Busca do baseline

Adotou-se busca coordenada: varre-se um eixo mantendo os demais congelados, fixa-se o melhor valor e prossegue-se ao eixo seguinte. O procedimento produz aproximadamente dez execuções, contra as dezenas de uma busca exaustiva, e gera tabelas interpretáveis por eixo.

Calibração prévia do orçamento. Sondagens iniciais com 3.000 épocas indicaram que a perda de validação ainda decrescia ao final do orçamento (mínimo na época 2.967 de 3.000), configurando treino interrompido e não sobreajuste. Nesse regime, regularizadores só poderiam degradar o desempenho. Com 10.000 épocas, o erro de treino atinge 0,0106 — *abaixo* do piso de ruído padronizado (0,0131) —, contra 0,0197 de validação, caracterizando sobreajuste. Adotou-se 10.000 épocas.

Registra-se um achado metodológico relevante: nas sondagens com 3.000 épocas, a topologia [128] aparecia inferior a [64] (0,9105 contra 0,9314), ao passo que com 10.000 épocas a ordem se inverte (0,9516 contra 0,8822). Redes maiores convergem mais lentamente; **comparar arquiteturas sob orçamento insuficiente inverte o ranking**, o que justifica calibrar o orçamento antes da busca.

Tabela 1: Busca coordenada para regressão. Métricas em validação, 3 sementes, 10.000 épocas.

Eixo	Valor	R^2	RMSE
Largura	[16]	$0,8633 \pm 0,0291$	0,6290
	[32]	$0,8770 \pm 0,0551$	0,5824
	[64]	$0,8822 \pm 0,0730$	0,5610
	[128]	$0,9516 \pm 0,0051$	0,3761
Profundidade	[128]	$0,9516 \pm 0,0051$	0,3761
	[128, 128]	$0,9756 \pm 0,0022$	0,2671
	[128, 128, 128]	$0,9780 \pm 0,0012$	0,2539
Taxa de aprendizado	0,01	$0,9742 \pm 0,0031$	0,2745
	0,05	$0,9780 \pm 0,0012$	0,2539
	0,10	$0,9763 \pm 0,0007$	0,2634

Baseline adotado: [128, 128], lr = 0,05. A busca maximizou R^2 e apontou [128, 128, 128]. Adotou-se, contudo, a rede de duas camadas: a terceira camada rende +0,0024 de R^2 ao custo de dobrar o número de parâmetros (de 16.897 para 33.409), e 0,0024 é da ordem do próprio

desvio entre sementes (0,0022). Pelo critério estabelecido na metodologia, o ganho não constitui sinal.

Observa-se, adicionalmente, que o desvio entre sementes decresce à medida que o modelo melhora (0,073 em [64], 0,005 em [128], 0,001 em [128, 128, 128]): modelos subdimensionados dependem substancialmente mais da inicialização.

3.4 Estudo de ablação

Tabela 2: Ablações na regressão. Baseline [128, 128], lr 0,05, $R^2 = 0,9756 \pm 0,0022$. Validação, 3 sementes.

Componente	Valor	R^2	ΔR^2
L1	10^{-6}	$0,9754 \pm 0,0028$	-0,0002
	10^{-5}	$0,9749 \pm 0,0024$	-0,0006
	10^{-4}	$0,9738 \pm 0,0015$	-0,0018
L2	10^{-5}	$0,9755 \pm 0,0025$	-0,0000
	10^{-4}	$0,9744 \pm 0,0026$	-0,0011
	10^{-3}	$0,9631 \pm 0,0060$	-0,0125
Dropout	0,1	$0,9745 \pm 0,0026$	-0,0011
	0,2	$0,9689 \pm 0,0016$	-0,0067
	0,5	$0,9225 \pm 0,0031$	-0,0531
Momentum	0,5	$0,9776 \pm 0,0010$	+0,0021
	0,9	$0,9493 \pm 0,0180$	-0,0263
	0,99	$0,2175 \pm 0,3863$	-0,7581

Os três regularizadores degradam o desempenho de forma *monotônica*, e nos três o melhor valor é o menor testado — isto é, situado na borda inferior da faixa. Estender a faixa nessa direção equivale a caminhar para $\lambda \rightarrow 0$, que é o próprio baseline. A leitura correta é que **o valor ótimo dos três regularizadores é zero**.

O resultado possui explicação mecânica: a distância entre erro de treino e de validação é modesta (0,0106 contra 0,0197), não há degradação temporal a corrigir, e o R^2 de 0,9756 dista apenas 0,011 do teto imposto pelo ruído. Não resta variância suficiente para compensar o viés introduzido pela penalização.

O comportamento do momentum é previsível pela relação entre passo efetivo e coeficiente, $\text{lr}_{\text{ef}} \approx \text{lr}/(1 - \beta)$. Para $\beta = 0,5$ obtém-se $\text{lr}_{\text{ef}} = 0,10$, valor que na Tabela 1 rendeu 0,9763; para $\beta = 0,99$, $\text{lr}_{\text{ef}} = 5,0$, e o desvio (0,3863) superior à própria média indica divergência completa em ao menos uma semente. Ressalta-se que o momentum é o único dos quatro componentes que não constitui regularização, mas aceleração.

3.5 Resultados no conjunto de teste

A coluna *degradação* corresponde à razão entre a média da perda de validação nas últimas mil épocas e a média em mil épocas centrais do treino; valores superiores a 1 indicam piora. Todos os modelos situam-se em torno de 0,91, isto é, a validação ainda melhorava ao final do orçamento. **Não há sobreajuste temporal na regressão**; o sobreajuste presente é estrutural, manifesto na distância entre treino e validação.

Duas observações. Primeiro, o desempenho no teste superou o de validação em todos os modelos ($\approx 0,983$ contra $\approx 0,976$); com apenas 45 pontos em cada partição, a diferença é variação amostral e não deve ser interpretada como generalização superior. Segundo, a ordenação dos modelos é idêntica nas duas partições, o que evidencia que a seleção por validação não enviesou

Tabela 3: Resultados finais da regressão. Conjunto de teste, acessado uma única vez.

Modelo	R^2 (validação)	R^2 (teste)	MAE	RMSE	Degradação
Baseline	$0,9756 \pm 0,0022$	$0,9829 \pm 0,0018$	0,1922	0,2372	0,912
L1 10^{-6}	$0,9754 \pm 0,0028$	$0,9828 \pm 0,0022$	0,1937	0,2378	0,901
L2 10^{-5}	$0,9755 \pm 0,0025$	$0,9828 \pm 0,0023$	0,1930	0,2376	0,905
Dropout 0,1	$0,9745 \pm 0,0026$	$0,9783 \pm 0,0034$	0,2193	0,2667	0,903
Momentum 0,5	$0,9776 \pm 0,0010$	$0,9842 \pm 0,0020$	0,1879	0,2277	0,915

a conclusão final. O ganho do momentum 0,5 no teste (+0,0013) permanece dentro da variação entre sementes e não é, portanto, demonstrável.

3.6 Limite representacional na descontinuidade




Figura 1: Baseline da regressão ($[128, 128]$, $lr=0,05$). À esquerda, escala logarítmica; à direita, ampliação em torno de $x = 2$.

A Figura 1(b) evidencia o limite representacional previsto. Onde $f(x)$ apresenta salto vertical em $x = 2$, a rede produz uma rampa de largura aproximada 0,17, iniciada em $x \approx 1,85$, antecipando a descontinuidade; observa-se ainda leve subestimação na região $1,4 \leq x \leq 1,8$.

O fenômeno não decorre de treino insuficiente nem de capacidade inadequada. Uma MLP é uma composição de funções contínuas e, portanto, *não pode* representar uma descontinuidade — apenas aproximá-la por uma rampa de inclinação finita, linear por partes no caso da ativação ReLU. Aumentar a capacidade estreita a rampa, mas não a elimina.

4 Problema 2: Classificação

4.1 Dados e preparação

Utilizou-se o Fashion-MNIST: 60.000 imagens de treino e 10.000 de teste, 28×28 em tons de cinza, dez classes balanceadas. Preservou-se o conjunto de teste oficial e extraíram-se 10.000 imagens do treino para validação, resultando em 50.000/10.000/10.000 — proporções coerentes com as adotadas na regressão e comparáveis com a literatura.

A padronização utilizou média e desvio *escalares* calculados sobre o treino ($\mu = 0,2858$, $\sigma = 0,3528$), e não por pixel: os pixels de borda são quase sempre nulos e apresentariam desvio aproximadamente zero, produzindo divisões inválidas. Adotou-se *batch* de 128, contra 32 na regressão, dado que o conjunto é 238 vezes maior; registra-se que *batches* maiores produzem gra-

dientes menos ruidosos, e que o ruído do *mini-batch* constitui em si uma regularização implícita leve.

Perda da estrutura espacial. A conversão $28 \times 28 \rightarrow 784$ elimina a noção de vizinhança entre pixels: a rede recebe 784 valores independentes e uma permutação fixa das colunas produziria resultado idêntico. Esta limitação é retomada na Seção 4.6.

Critério de decisão. Como o conjunto é balanceado, acurácia e F1 macro praticamente coincidem (mediu-se 0,8853 para ambos), e adotou-se a acurácia de validação como critério, por ser mais interpretável. Precisão, revocação e F1 macro são reportados conforme solicitado. Registra-se que, em cenário desbalanceado, o critério deveria migrar para F1 macro, por a acurácia passar a ser dominada pelas classes majoritárias.

4.2 Calibração do orçamento

Sondagem com $[128, 128]$ e 60 épocas revelou comportamento oposto ao da regressão: a perda de validação atinge mínimo na época 19 e piora 32% até o final do orçamento, com erro de treino de 0,0768 contra 0,4300 de validação. Há, portanto, **sobreajuste temporal claro**. Adotou-se orçamento de 60 épocas, aproximadamente três vezes o ponto de inflexão.

Registra-se uma previsão inicial incorreta: esperava-se *menos* sobreajuste na classificação, por raciocínio baseado em parâmetros por amostra ($\approx 2,4$ contra 80 na regressão). O raciocínio falha porque a razão entre parâmetros e amostras é indicador inadequado de capacidade efetiva em classificação de alta dimensionalidade: com entropia cruzada, a rede reduz a perda de treino a valores próximos de zero memorizando padrões idiossincráticos em 784 dimensões.

4.3 Busca do baseline

Tabela 4: Busca coordenada para classificação. Acurácia de validação, 3 sementes, 60 épocas.

Eixo	Valor	Acurácia
Largura	[64]	$0,8672 \pm 0,0081$
	[128]	$0,8859 \pm 0,0037$
	[256]	$0,8882 \pm 0,0028$
Profundidade	[256]	$0,8882 \pm 0,0028$
	[256, 256]	$0,8886 \pm 0,0028$
	[256, 256, 256]	$0,8874 \pm 0,0042$
Taxa de aprendizado	0,01	$0,8836 \pm 0,0029$
	0,05	$0,8886 \pm 0,0028$
	0,10	$0,8894 \pm 0,0028$

Apenas uma transição da Tabela 4 é estatisticamente significativa: $[64] \rightarrow [128]$, com $+0,0187$, aproximadamente cinco desvios. As demais diferenças situam-se dentro do ruído; em particular, a profundidade não produz ganho demonstrável.

Limitação da busca coordenada. Opções descartadas em um eixo não são reavaliadas com os hiperparâmetros finais dos eixos subsequentes: [128] foi medida com lr 0,05, ao passo que o baseline final emprega lr 0,1. Refez-se, portanto, a comparação em condições idênticas (Tabela 5).

Tabela 5: Comparação em condições idênticas ($lr = 0,1$) e diagnóstico de sobreajuste.

Topologia	Parâmetros	Acurácia	Pico da validação	Razão treino/validação
[128]	101.770	$0,8844 \pm 0,0021$	época 15	$6,9\times$
[128,128]	118.282	$0,8794 \pm 0,0045$	época 12	$13,3\times$
[256,256]	269.322	$0,8894 \pm 0,0028$	época 7	$18,2\times$

Baseline adotado: [256,256], $lr = 0,1$. A topologia supera [128] em $+0,0050$, aproximadamente 2,5 erros-padrão, portanto acima do limiar estabelecido. Nota-se o contraste com a regressão: aplicado o mesmo critério, lá a rede maior foi rejeitada (ganho de 1,1 desvio) e aqui é aceita. O critério de parcimônia opera como teste, não como preferência.

A Tabela 5 exibe ainda, de forma nítida, o compromisso entre viés e variância: quanto maior a rede, mais cedo ocorre o pico da validação (épocas 15, 12 e 7) e maior a razão entre erros de treino e validação ($6,9\times$, $13,3\times$, $18,2\times$). Tal comportamento não se manifestou na regressão, por inexistir variância excessiva a penalizar.

Divergência entre perda e acurácia. A topologia [256,256] é simultaneamente a de maior sobreajuste e a de melhor acurácia. Não há contradição: a entropia cruzada penaliza confiança elevada em predições incorretas, de modo que a perda cresce enquanto a classe de maior ativação permanece correta. Conclui-se que, em classificação, **o sobreajuste manifesta-se primeiro na perda e apenas posteriormente na acurácia** — razão pela qual as curvas de perda são indispensáveis.

4.4 Estudo de ablação

Tabela 6: Ablações na classificação. Baseline [256,256], $lr = 0,1$, acurácia $0,8894 \pm 0,0028$. Validação, 3 sementes.

Componente	Valor	Acurácia	Δ
L1	10^{-6}	$0,8915 \pm 0,0019$	$+0,0021$
	10^{-5}	$0,8890 \pm 0,0017$	$-0,0004$
	10^{-4}	$0,8734 \pm 0,0050$	$-0,0160$
L2	10^{-5}	$0,8885 \pm 0,0031$	$-0,0009$
	10^{-4}	$0,8908 \pm 0,0030$	$+0,0014$
	10^{-3}	$0,8867 \pm 0,0106$	$-0,0027$
Dropout	0,1	$0,8913 \pm 0,0029$	$+0,0019$
	0,2	$0,8920 \pm 0,0022$	$+0,0026$
	0,5	$0,8911 \pm 0,0006$	$+0,0017$
Momentum	0,5	$0,8889 \pm 0,0022$	$-0,0005$
	0,9	$0,8740 \pm 0,0030$	$-0,0154$
	0,99	$0,1055 \pm 0,0000$	$-0,7839$

O padrão difere qualitativamente do observado na regressão: os três regularizadores apresentam melhor valor *positivo*, a L2 exibe ótimo *interior* — indicando faixa adequadamente dimensionada — e o *dropout* é positivo em todos os valores testados.

A acurácia de 0,1055 obtida com $\beta = 0,99$ corresponde exatamente ao acerto aleatório com dez classes. O desvio nulo e o F1 macro de 0,0192 revelam o mecanismo: as três sementes

convergir para prever sempre a mesma classe. Com $lr_{ef} = 0,1/(1 - 0,99) = 10,0$, não houve aprendizado.

O efeito real do dropout. A avaliação por acurácia subestima substancialmente o efeito do *dropout*, conforme a Tabela 7.

Tabela 7: Diagnóstico de sobreajuste dos melhores regularizadores.

Modelo	Acurácia	Perda val. (final)	Razão treino/val.	Pico	Degradação
Baseline	0,8894	0,5707	18,2×	época 7	1,289
Dropout 0,2	0,8920	0,3931	3,9×	época 21	1,139
L2 10^{-4}	0,8908	0,4959	15,6×	época 7	1,214

O *dropout* reduz a razão entre erros de 18,2× para 3,9× (queda de 79%), adia o pico da validação da época 7 para a 21 e diminui a perda de validação em 31%, ao passo que a acurácia aumenta apenas 0,3 ponto percentual. O erro de treino eleva-se de 0,0313 para 0,1004: a rede piora deliberadamente no treino e melhora em todo o restante, comportamento característico de regularização efetiva.

Conclui-se que **a métrica de decisão determina o que se consegue observar**. Por acurácia, o *dropout* constitui ganho marginal; por perda de validação, é o componente mais eficaz do estudo. A exigência de múltiplas métricas mostra-se, portanto, metodologicamente necessária.

4.5 Resultados no conjunto de teste

Tabela 8: Resultados finais da classificação. Conjunto de teste oficial, acessado uma única vez.

Modelo	Acur. (val.)	Acur. (teste)	F1 macro	Precisão	Revocação
Baseline	0,8894	0,8895 ± 0,0044	0,8896	0,8903	0,8895
L1 10^{-6}	0,8915	0,8899 ± 0,0037	0,8902	0,8910	0,8899
L2 10^{-4}	0,8908	0,8894 ± 0,0031	0,8897	0,8907	0,8894
Dropout 0,2	0,8920	0,8948 ± 0,0022	0,8942	0,8948	0,8948
Momentum 0,5	0,8889	0,8914 ± 0,0040	0,8915	0,8929	0,8914


O *dropout* apresenta desempenho superior no teste (+0,0053, aproximadamente 1,87 erros-padrão) ao obtido em validação (1,26). Permanece formalmente abaixo do limiar de dois erros-padrão, mas é o único componente cujo benefício se manifesta de modo consistente em todas as evidências coletadas.

Registra-se que, diferentemente da regressão, a ordenação dos modelos não se preservou entre validação e teste — o momentum 0,5 passou da quinta à segunda posição. Isto não caracteriza falha do protocolo: as diferenças entre os modelos intermediários ($\approx 0,002$) são inferiores aos desvios ($\approx 0,004$), de modo que tal ordenação nunca constituiu sinal.


4.6 Análise por classe

As três classes de menor revocação são *Shirt* (0,698), *Pullover* (0,815) e *T-shirt/top* (0,839); as demais superam 0,92, com *Trouser* em 0,97 e os três tipos de calçado acima de 0,95.

Os erros não se distribuem aleatoriamente, mas concentram-se em um bloco semanticamente coerente. *Shirt* é confundida com *T-shirt/top* (0,11), *Pullover* (0,08) e *Coat* (0,07); reciprocamente, *T-shirt/top* é atribuída a *Shirt* em 0,10 dos casos, e *Pullover* a *Coat* em 0,09. Todas as classes problemáticas correspondem a peças de tronco superior.



(a) Baseline.



(b) Com *dropout* 0,2.

Figura 2: Evolução do treino e da validação no Fashion-MNIST, escala logarítmica.




Figura 3: Matriz de confusão do baseline no conjunto de teste, normalizada por linha.

A interpretação conecta-se diretamente à perda da estrutura espacial: camiseta, camisa, pulôver e casaco possuem silhuetas praticamente idênticas, distinguindo-se por detalhes *locais* — gola, botões, punho, textura. Como a conversão para vetor de 784 elementos eliminou a noção de adjacência entre pixels, a MLP não dispõe de mecanismo para representar tais estruturas. **O limite de aproximadamente 89% de acurácia não decorre de sobreajuste, mas de representação**, o que explica por que nenhum regularizador o desloca de forma relevante. Uma arquitetura convolucional, que opera sobre vizinhanças, atacaria precisamente este bloco de erros.

5 Discussão

O resultado central deste trabalho emerge da comparação entre as Tabelas 2 e 6. Os mesmos quatro componentes, implementados no mesmo código, avaliados sob o mesmo protocolo e com as mesmas sementes, produziram conclusões opostas:

- na regressão, os três regularizadores degradaram o desempenho monotonicamente, com ótimo em zero — doze medições, todas negativas exceto o momentum 0,5;
- na classificação, os três apresentaram melhor valor positivo, com o *dropout* positivo em todos os valores testados.

A explicação é a quantidade de sobreajuste disponível. Na regressão, a razão entre erros de treino e validação era de $1,9\times$, sem degradação temporal, e o R^2 distava 0,011 do teto imposto pelo ruído: não havia variância excessiva a ser removida, e a penalização apenas introduziu viés. Na classificação, a razão era de $18,2\times$, com pico da validação na época 7 de 60: havia ampla variância a recuperar.

Dois pontos merecem qualificação. Primeiro, **nenhum ganho individual na classificação supera dois erros-padrão** — o melhor deles, *dropout* 0,2, atinge 1,87 no teste. Afirmar superioridade com base em uma medição isolada excederia o que três sementes sustentam. O que se sustenta é a mudança do *padrão*: três resultados positivos em três no *dropout*, contra doze negativos na regressão, além do efeito inequívoco nas métricas de sobreajuste.

Segundo, os dois problemas apresentam limites de natureza distinta. Na regressão, o limite é o ruído ($R^2_{\max} = 0,987$, contra 0,976 obtidos) somado à impossibilidade de representar a descontinuidade. Na classificação, o limite é a ausência de estrutura espacial na entrada, evidenciada pelo bloco de confusão entre peças de vestuário superior. Em nenhum dos casos o fator limitante é aquele que os componentes avaliados se propõem a corrigir — o que explica a modéstia dos ganhos observados.

6 Conclusão

Construíram-se dois modelos MLP de referência por busca coordenada ([128,128] com lr 0,05 para regressão; [256,256] com lr 0,1 para classificação) e avaliaram-se quatro componentes adicionados isoladamente, com três sementes por configuração.

Os resultados finais em teste são $R^2 = 0,9829 \pm 0,0018$ para a regressão e acurácia de $0,8895 \pm 0,0044$ para a classificação, com o *dropout* 0,2 alcançando $0,8948 \pm 0,0022$ nesta última. Nenhum componente produziu ganho estatisticamente demonstrável em acurácia ou R^2 ; o *dropout*, contudo, exibiu efeito grande e inequívoco sobre as métricas de sobreajuste na classificação.

Três achados metodológicos merecem destaque. A comparação de arquiteturas sob orçamento de épocas insuficiente inverteu o ranking observado, o que justifica calibrar o orçamento previamente. A métrica adotada para decisão determinou o que foi possível observar, ocultando quase integralmente o efeito do *dropout* quando se considerou apenas a acurácia. E o emprego de três sementes revelou-se indispensável, não por reduzir ruído, mas por fornecer o critério que

distingue ganho de variação — critério que, aplicado consistentemente, rejeitou a rede maior em um problema e a aceitou no outro.

Referências

- [1] RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. *Learning representations by back-propagating errors*. Nature, v. 323, p. 533–536, 1986.
- [2] SRIVASTAVA, N. et al. *Dropout: A Simple Way to Prevent Neural Networks from Overfitting*. Journal of Machine Learning Research, v. 15, p. 1929–1958, 2014.
- [3] XIAO, H.; RASUL, K.; VOLLGRAF, R. *Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms*. arXiv:1708.07747, 2017.